Universidade Federal do Ceará

Departamento de Estatística e Matemática Aplicada

Introdução à Mineração de Dados (CC0101), período 2019.1

Professor: Tibérius O. Bonates (tb@ufc.br).

Atividade 2 – Algoritmo de seleção de protótipos para K-NN.

## 1 Descrição

Implementar em Python, com base no material discutido em sala de aula e no livro-texto, **um dos dois** algoritmos de seleção de protótipos para K-NN (chamados de "Edit k-NN" na seção 4.5 do livro-texto – Algoritmos 4.2 e 4.3). Fique à vontade para escolher qual dos dois algoritmos você irá implementar.

Para esta atividade, você terá que chamar várias vezes alguma implementação do algoritmo K-NN. Fique à vontade para usar a implementação desenvolvida em sala de aula, a implementação do pacote scikit-learn, ou mesmo alguma outra implementação que você encontre/conheça.

Além de escrever o código, você deve realizar uma comparação de acurácia (percentual de acertos) entre o algoritmo K-NN e o algoritmo K-NN com o preprocessamento "Edit k-NN". Chamaremos essas duas versões do K-NN de "K-NN básico" e "K-NN com edição", respectivamente.

Utilize valores de K iguais a 2, 3, e 5. Utilize, também, um conjunto de dados de domínio público (tal como Iris, Iris2D, ou outro de sua preferência) e, para cada valor de K, faça 10 partições aleatórias do conjunto de dados em 50% de dados de treinamento e 50% de dados de teste. Para cada partição, utilize tanto o algoritmo **K-NN básico** quanto o algoritmo **K-NN com edição** para classificar os dados de teste com base na informação dos dados de treinamento e registre a acurácia de cada um dos algoritmos.

## 2 Entrega

- Pontuação total pela atividade: 1,5 pontos (um ponto e meio).
- Entregáveis:
  - código-fonte em Python;
  - relatório em formato PDF contendo uma tabela com pelo menos 30 linhas (10 partições aleatórias para cada um dos 3 valores de K). Para cada valor de K, forneça também a acurácia média de cada um dos dois algoritmos.
- Data de entrega: 7 de abril de 2019, 23:59:59, via SIGAA. Não via e-mail.
- Data de entrega com adiamento automático: 14 de abril de 2019, 23:59:59, via SIGAA. Não via e-mail.

## 3 Trilha Sonora Sugerida

https://www.youtube.com/watch?v=gUdDeqU9aZQ

## 4 Mais detalhes

• A atividade pode ser feita individualmente ou em dupla. Sintam-se encorajados(as) a fazer a atividade em dupla. Os nomes dos(as) participantes da equipe devem estar no código-fonte, e não em mensagem via SIGAA.